# Лабораторная работа №5 по курсу «Методы машинного обучения»

«Линейные модели, SVM и деревья решений»

Выполнила:

Чекулина М.Ю. Группа ИУ5-22М

# Линейные модели, SVM и деревья решений.

Цель лабораторной работы: изучение линейных моделей, SVM и деревьев решений. Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train\_test\_split разделите выборку на обучающую и тестовую.
- 4. Обучите одну из линейных моделей, SVM и 3 дерево решений. Оцените качество моделей с помощью трех подходящих для задачи метрик. Сравните качество полученных моделей.
- 5. Произведите для каждой модели подбор одного гиперпараметра с использованием GridSearchCV и кросс-валидации.
- 6. Повторите пункт 4 для найденных оптимальных значений гиперпараметров. Сравните качество полученных моделей с качеством моделей, полученных в пункте 4.

```
In [1]: import numpy as np
   import pandas as pd
   import seaborn as sns
   import matplotlib.pyplot as plt
   %matplotlib inline
   sns.set(style="ticks")
   data = pd.read_csv('Data/lab_5/winequalityN.csv',sep=",")
   data.head(5)
```

#### Out[1]:

_		type	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	рН	sulpha
	0	white	7.0	0.27	0.36	20.7	0.045	45.0	170.0	1.0010	3.00	О
	1	white	6.3	0.30	0.34	1.6	0.049	14.0	132.0	0.9940	3.30	О
	2	white	8.1	0.28	0.40	6.9	0.050	30.0	97.0	0.9951	3.26	О
	3	white	7.2	0.23	0.32	8.5	0.058	47.0	186.0	0.9956	3.19	О
	4	white	7.2	0.23	0.32	8.5	0.058	47.0	186.0	0.9956	3.19	О

```
In [2]: data.shape
```

Out[2]: (6497, 13)

```
In [3]: # Кодирование категориального признака(тип вина: красное или белое)

в столбец wine_type_le

from sklearn.preprocessing import LabelEncoder

le = LabelEncoder()

le.fit(data.type)

data['wine_type_le'] = le.transform(data.type)

data.head(2)
```

#### Out[3]:

	type	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides		sulfur dioxide	density	рН	sulphato
0	white	7.0	0.27	0.36	20.7	0.045	45.0	170.0	1.001	3.0	0.4
1	white	6.3	0.30	0.34	1.6	0.049	14.0	132.0	0.994	3.3	0.4

```
In [4]: del data['type']
```

### In [5]: data.head(2)

#### Out[5]:

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides		total sulfur dioxide	density	рН	sulphates	alc
0	7.0	0.27	0.36	20.7	0.045	45.0	170.0	1.001	3.0	0.45	
1	6.3	0.30	0.34	1.6	0.049	14.0	132.0	0.994	3.3	0.49	

# In [6]: # Проверка на пустые значения data.isnull().sum()

```
Out[6]: fixed acidity
                                  10
        volatile acidity
                                   8
        citric acid
                                   3
        residual sugar
                                   2
        chlorides
                                   2
        free sulfur dioxide
                                   0
        total sulfur dioxide
                                   0
        density
                                   0
                                   9
        рН
        sulphates
                                   4
                                   0
        alcohol
        quality
                                   0
        wine_type_le
                                   0
        dtype: int64
```

```
In [7]: import pandas as pd
         # function to clean the dataset of nan, Inf, and missing cells (for
         skewed datasets)
         def clean dataset(df):
             assert isinstance(df, pd.DataFrame), "df needs to be a pd.DataF
         rame"
             df.dropna(inplace=True)
             indices to keep = ~df.isin([np.nan, np.inf, -np.inf]).any(1)
             return df[indices to keep].astype(np.float64)
 In [8]: clean dataset(data)[:1]
Out[8]:
                                               free
                                                      total
             fixed volatile citric residual
                                     chlorides
                                                     sulfur density pH sulphates alc
                                              sulfur
            acidity
                  acidity
                         acid
                                sugar
                                             dioxide
                                                    dioxide
               7.0
          0
                     0.27
                          0.36
                                 20.7
                                        0.045
                                               45.0
                                                     170.0
                                                            1.001 3.0
                                                                         0.45
In [9]: # Пустых значений нет
         # Перейдем к разделению выборки на обучающую и тестовую.
         X = data.drop('wine type le',axis = 1).values
         y = data['wine type le'].values
         from sklearn.model selection import train test split
In [10]:
         # Функция train test split разделила исходную выборку таким образом
         #чтобы в обучающей и тестовой частях сохранились пропорции классов.
         X train, X test, y train, y test = train test split(
             X, y, test size=0.30, random state=1)
In [11]: # Размер обучающей выборки (70%)
         print('X train: {} y train: {}'.format(X train.shape, y train.shap
         e))
         X train: (4524, 12) y train: (4524,)
In [12]: # Размер тестовой выборки (30%)
         print('X_test: {} '.format(X_test.shape, y_test.shape))
         X test: (1939, 12) y test: (1939,)
In [13]: # Функция train test split разделила исходную выборку таким образом
         #чтобы в обучающей и тестовой частях сохранились пропорции классов.
         np.unique(y train)
Out[13]: array([0, 1])
```

```
In [14]: np.unique(y_test)
Out[14]: array([0, 1])
In [15]: from sklearn.linear_model import SGDClassifier
    from sklearn.svm import LinearSVC
    from sklearn.tree import DecisionTreeClassifier
    from sklearn.model_selection import GridSearchCV

from sklearn.metrics import accuracy_score
    from sklearn.metrics import balanced_accuracy_score
    from sklearn.metrics import precision_score, recall_score, fl_score
```

# Сравнение качества трех линейных моделей

## SGDClassifier (градиентный метод)

```
In [16]: import warnings
    warnings.filterwarnings('ignore')
    sgd = SGDClassifier().fit(X_train, y_train)
    predicted_sgd = sgd.predict(X_test)

In [17]: accuracy_score(y_test, predicted_sgd)

Out[17]: 0.7741103661681279

In [18]: balanced_accuracy_score(y_test, predicted_sgd)

Out[18]: 0.8412864309603441

In [19]: (precision_score(y_test, predicted_sgd, average='weighted'), recall_score(y_test, predicted_sgd, average='weighted'))

Out[19]: (0.8730518980385593, 0.7741103661681279)

In [20]: f1_score(y_test, predicted_sgd, average='weighted')

Out[20]: 0.7892751746523573
```

# LinearSVC (линейный)

### DecisionTreeClassifier (дерево решений)

```
In [26]: dtc = DecisionTreeClassifier(random_state=1).fit(X_train, y_train)
    predicted_dtc = dtc.predict(X_test)

In [27]: accuracy_score(y_test, predicted_dtc)

Out[27]: 0.9896854048478597

In [28]: balanced_accuracy_score(y_test, predicted_dtc)

Out[28]: 0.9882893374741202

In [29]: (precision_score(y_test, predicted_dtc, average='weighted'),
    recall_score(y_test, predicted_dtc, average='weighted'))

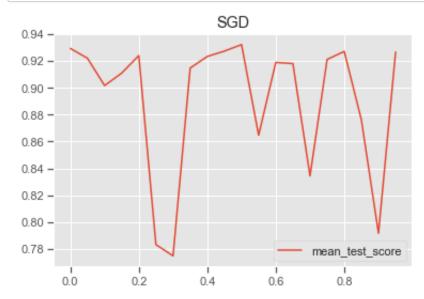
Out[29]: (0.9897527301109915, 0.9896854048478597)

In [30]: f1_score(y_test, predicted_dtc, average='weighted')

Out[30]: 0.9897065917780767
```

# Подбор одного гиперпараметра с использованием GridSearchCV и кросс-валидации

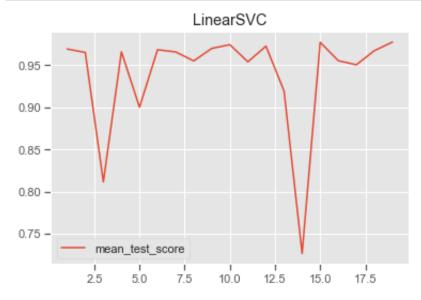
```
In [32]: import warnings
         warnings.filterwarnings('ignore')
         clf gs sgd = GridSearchCV(SGDClassifier(), tuned parameters, cv=5,
                               scoring='accuracy')
         clf gs sgd.fit(X train, y train)
Out[32]: GridSearchCV(cv=5, error score='raise-deprecating',
                estimator=SGDClassifier(alpha=0.0001, average=False, class
         weight=None,
                early stopping=False, epsilon=0.1, eta0=0.0, fit intercept=
         True,
                11_ratio=0.15, learning_rate='optimal', loss='hinge', max i
         ter=None,
                n iter=None, n iter no change=5, n jobs=None, penalty='12',
                power t=0.5, random state=None, shuffle=True, tol=None,
                validation fraction=0.1, verbose=0, warm start=False),
                fit params=None, iid='warn', n jobs=None,
                param grid=[{'l1 ratio': array([0. , 0.05, 0.1 , 0.15, 0.2
         , 0.25, 0.3 , 0.35, 0.4 , 0.45, 0.5 ,
                0.55, 0.6, 0.65, 0.7, 0.75, 0.8, 0.85, 0.9, 0.95])
                pre_dispatch='2*n_jobs', refit=True, return_train_score='wa
         rn',
                scoring='accuracy', verbose=0)
In [33]: clf gs sgd.best params
Out[33]: {'ll ratio': 0.5}
In [34]: import matplotlib.pyplot as plt
         plt.style.use('ggplot')
```



```
In [36]: n_range = np.array(range(1,20,1))
  tuned_parameters = [{'C': n_range}]
  tuned_parameters
```

```
Out[36]: [{'C': array([ 1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19])}]
```

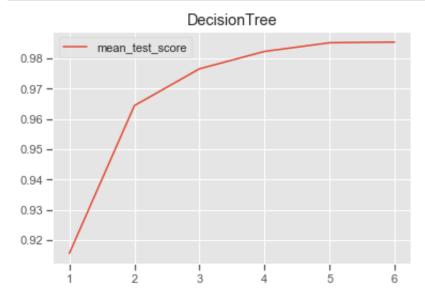
```
In [38]: clf_gs_svm.best_params_
Out[38]: {'C': 19}
In [39]: plt.title('LinearSVC')
    plt.plot(n_range, clf_gs_svm.cv_results_['mean_test_score'],label='
        mean_test_score')
    plt.legend()
    plt.show()
```



```
In [40]: n range = np.array(range(1,7,1))
         tuned parameters = [{'max depth': n range}]
         tuned parameters
Out[40]: [{'max_depth': array([1, 2, 3, 4, 5, 6])}]
In [41]: clf gs dt = GridSearchCV(DecisionTreeClassifier(random state=1), tu
         ned parameters,
                                   cv=5, scoring='accuracy')
         clf gs dt.fit(X train, y train)
Out[41]: GridSearchCV(cv=5, error score='raise-deprecating',
                estimator=DecisionTreeClassifier(class weight=None, criteri
         on='gini', max depth=None,
                     max features=None, max leaf nodes=None,
                     min_impurity_decrease=0.0, min_impurity_split=None,
                     min_samples_leaf=1, min_samples split=2,
                     min weight fraction leaf=0.0, presort=False, random st
         ate=1,
                     splitter='best'),
                fit_params=None, iid='warn', n_jobs=None,
                param_grid=[{'max_depth': array([1, 2, 3, 4, 5, 6])}],
                pre dispatch='2*n jobs', refit=True, return train score='wa
         rn',
                scoring='accuracy', verbose=0)
```

```
In [42]: clf_gs_dt.best_params_
Out[42]: {'max_depth': 6}

In [43]: plt.title('DecisionTree')
    plt.plot(n_range, clf_gs_dt.cv_results_['mean_test_score'],label='mean_test_score')
    plt.legend()
    plt.show()
```



# Сравнение качества полученных моделей с качеством моделей, полученных ранее

### **SGD**

```
In [48]: f1_score(y_test, predicted_sgd_opt, average='weighted')
Out[48]: 0.9399744973367767
```

#### LinearSVC

#### **DecisionTree**

```
In [58]: f1_score(y_test, predicted_dt_opt, average='weighted')
Out[58]: 0.9896710352653659
```

Вывод наибольшая точность у дерева решений, затем идет линейный метод, а потом SGD (стохастический градиентный метод)