### Московский государственный технический университет им. Н.Э. Баумана

Кафедра «Системы обработки информации и управления»

# Лабораторная работа №6 по курсу «Методы машинного обучения»

«Ансамбли моделей машинного обучения»

Выполнила:

Чекулина М.Ю. Группа ИУ5-22М

# **Ансамбли моделей машинного** обучения

Цель лабораторной работы: изучение ансамблей моделей машинного обучения. Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train\_test\_split разделите выборку на обучающую и тестовую.
- 4. Обучите две ансамблевые модели. Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.
- 5. Произведите для каждой модели подбор значений одного гиперпараметра. В зависимости от используемой библиотеки можно применять функцию GridSearchCV, использовать перебор параметров в цикле, или использовать другие методы.
- 6. Повторите пункт 4 для найденных оптимальных значений гиперпараметров. Сравните качество полученных моделей с качеством моделей, полученных в пункте 4.

```
In [1]: import numpy as np
    import pandas as pd
    import seaborn as sns
    import matplotlib.pyplot as plt
    %matplotlib inline
    sns.set(style="ticks")
    data = pd.read_csv('Data/lab_4/heart.csv',sep=",")
    data.head(5)
```

#### Out[1]:

	age	sex	ср	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	targ
0	63	1	3	145	233	1	0	150	0	2.3	0	0	1	
1	37	1	2	130	250	0	1	187	0	3.5	0	0	2	
2	41	0	1	130	204	0	0	172	0	1.4	2	0	2	
3	56	1	1	120	236	0	1	178	0	8.0	2	0	2	
4	57	0	0	120	354	0	1	163	1	0.6	2	0	2	

```
In [2]: data.shape
Out[2]: (303, 14)
In [3]: # Проверка на пустые значения
        data.isnull().sum()
Out[3]: age
                     0
        sex
                     0
                     0
        ср
                     0
        trestbps
        chol
                     0
        fbs
                     0
        restecg
                     0
        thalach
                     0
        exang
                     0
        oldpeak
                     0
        slope
                     0
                     0
        ca
                     0
        thal
        target
        dtype: int64
```

## **Feature Scaling**

```
In [4]: from sklearn.preprocessing import MinMaxScaler
        import warnings
        warnings.filterwarnings('ignore')
        # Create the scaler object with a range of 0-1
        scaler = MinMaxScaler(feature range=(0, 1))
        # Fit on data, transform data
        scaler.fit transform(data)
Out[4]: array([[0.70833333, 1.
                                                   , ..., 0.
                                       , 1.
                                                                    , 0.33333
        333,
               [0.16666667, 1.
                                       , 0.66666667, ..., 0.
                                                                    , 0.66666
        667,
                1.
                                       , 0.33333333, ..., 0.
               [0.25]
                                                                    , 0.66666
        667,
                1.
                          1,
               [0.8125
                           , 1.
                                       , 0.
                                                   , ..., 0.5
                                                                   , 1.
               [0.58333333, 1.
                                       , 0.
                                                   , ..., 0.25
                                                                    , 1.
                0.
               [0.58333333, 0.
                                       , 0.33333333, ..., 0.25
                                                                    , 0.66666
        667,
                0.
                           11)
In [5]: from sklearn import svm
        from sklearn.neighbors import KNeighborsClassifier
        from sklearn.ensemble import RandomForestClassifier
        from sklearn.linear model import LogisticRegression
        from sklearn.metrics import roc curve, auc
        import pylab as pl
```

```
In [6]: # Пустых значений нет
# Перейдем к разделению выборки на обучающую и тестовую.
X = data.drop('target',axis = 1).values
y = data['target'].values
```

### Ансамблевые модели

```
In [7]: from sklearn.model_selection import train_test_split kfold = 5 #количество подвыборок для валидации itog_val = {} #СПИСОК ДЛЯ ЗаПИСИ РЕЗУЛЬТАТОВ КРОСС ВАЛИДАЦИИ РАЗНЫХ АЛ
```

```
In [8]: ROCtrainTRN, ROCtestTRN, ROCtrainTRG, ROCtestTRG = train_test_split(X,
```

```
In [9]: model_rfc = RandomForestClassifier(n_estimators = 70) #В параметре пер model_knc = KNeighborsClassifier(n_neighbors = 18) #В параметре передо model_lr = LogisticRegression(penalty='ll', tol=0.01) model_svc = svm.SVC() #ПО УМОЛЧАНИЮ kernek='rbf'
```

In [10]: from sklearn.model\_selection import cross\_val\_score

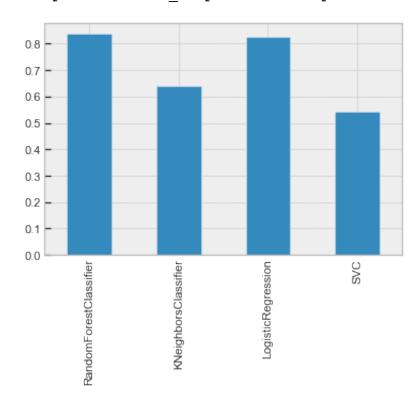
SVM - метод опорных векторов(SVC): Суть работы "Машин" Опорных Векторов проста: алгоритм создает линию или гиперплоскость, которая разделяет данные на классы. Метод k-ближайших соседей(KNeighborsClassifier) Random forest(RandomForestClassifier) Логистическая регрессия (LogisticRegression)

In [11]: from sklearn.ensemble import ExtraTreesClassifier, ExtraTreesRegressor

```
In [12]: scores = cross_val_score(model_rfc, X, y, cv = kfold)
    itog_val['RandomForestClassifier'] = scores.mean()
    scores = cross_val_score(model_knc, X, y, cv = kfold)
    itog_val['KNeighborsClassifier'] = scores.mean()
    scores = cross_val_score(model_lr, X, y, cv = kfold)
    itog_val['LogisticRegression'] = scores.mean()
    scores = cross_val_score(model_svc, X, y, cv = kfold)
    itog_val['SVC'] = scores.mean()
```

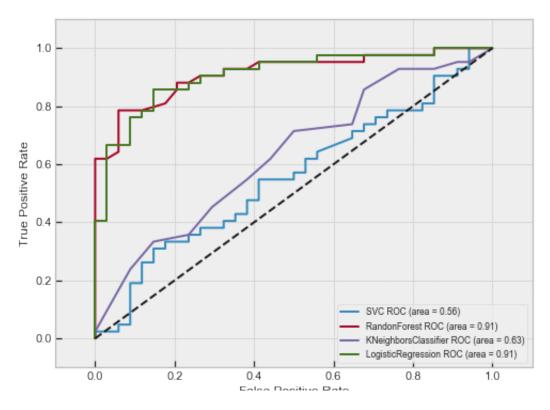
```
In [13]: import matplotlib.pyplot as plt
    plt.style.use('bmh')
    data.from_dict(data = itog_val, orient='index').plot(kind='bar', leger
```

Out[13]: <matplotlib.axes. subplots.AxesSubplot at 0x1a1e343240>



```
In [14]: pl.clf()
         plt.figure(figsize=(8,6))
         #SVC
         model svc.probability = True
         probas = model svc.fit(ROCtrainTRN, ROCtrainTRG).predict proba(ROCtest
         fpr, tpr, thresholds = roc curve(ROCtestTRG, probas[:, 1])
         roc auc = auc(fpr, tpr)
         pl.plot(fpr, tpr, label='%s ROC (area = %0.2f)' % ('SVC', roc auc))
         #RandomForestClassifier
         probas = model rfc.fit(ROCtrainTRN, ROCtrainTRG).predict proba(ROCtest
         fpr, tpr, thresholds = roc curve(ROCtestTRG, probas[:, 1])
         roc auc = auc(fpr, tpr)
         pl.plot(fpr, tpr, label='%s ROC (area = %0.2f)' % ('RandonForest',roc
         #KNeighborsClassifier
         probas = model knc.fit(ROCtrainTRN, ROCtrainTRG).predict proba(ROCtest
         fpr, tpr, thresholds = roc curve(ROCtestTRG, probas[:, 1])
         roc auc = auc(fpr, tpr)
         pl.plot(fpr, tpr, label='%s ROC (area = %0.2f)' % ('KNeighborsClassifi
         #LogisticRegression
         probas = model lr.fit(ROCtrainTRN, ROCtrainTRG).predict proba(ROCtestT
         fpr, tpr, thresholds = roc curve(ROCtestTRG, probas[:, 1])
         roc auc = auc(fpr, tpr)
         pl.plot(fpr, tpr, label='%s ROC (area = %0.2f)' % ('LogisticRegression')
         pl.plot([0, 1], [0, 1], 'k--')
         pl.xlim([-0.1, 1.1])
         pl.ylim([-0.1, 1.1])
         pl.xlabel('False Positive Rate')
         pl.ylabel('True Positive Rate')
         pl.legend(loc=0, fontsize='small')
         pl.show()
```

<Figure size 432x288 with 0 Axes>



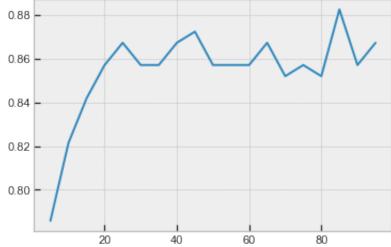
raise rusilive rate

```
In [15]: from sklearn.ensemble import RandomForestClassifier, AdaBoostClassifie
         from sklearn.metrics import accuracy score
         from sklearn.metrics import balanced accuracy score
         from sklearn.metrics import precision score, recall score, f1 score
In [16]: | from sklearn.model selection import train test split
         # Функция train test split разделила исходную выборку таким образом,
         #чтобы в обучающей и тестовой частях сохранились пропорции классов.
         X train, X test, y train, y test = train test split(
             X, y, test size=0.35, random state=1)
In [17]: | from sklearn.preprocessing import MinMaxScaler
         import warnings
         warnings.filterwarnings('ignore')
         # Create the scaler object with a range of 0-1
         scaler = MinMaxScaler(feature range=(0, 1))
         # Fit on data, transform data
         scaler.fit transform(X)
         scaler.fit transform(X train)
         scaler.fit transform(X test)
Out[17]: array([[0.77777778, 0.
                                                                     , 0.75
                                        , 0.
                                                    , ..., 0.
                           ],
                [0.61111111, 1.
                                        , 0.33333333, ..., 1.
                           1,
                [0.38888889, 1.
                                        , 0.
                                                                     , 0.5
                 1.
                           ],
                . . . ,
                [0.52777778, 1.
                                        , 0.
                                                   , ..., 0.
                                                                     , 0.
                           ],
                [0.66666667, 1.
                                        , 0.33333333, ..., 0.5
                                                                     , 1.
                           ],
                [0.38888889, 1.
                                        , 0.33333333, ..., 0.
                                                                     , 0.
                 1.
                           11)
In [18]: # n estimators = 10 (default)
         rfc = RandomForestClassifier().fit(X train, y train)
         predicted_rfc = rfc.predict(X_test)
In [19]: accuracy score(y test, predicted rfc)
```

Out[19]: 0.7570093457943925

```
In [20]: balanced accuracy score(y test, predicted rfc)
Out[20]: 0.7547368421052632
         (precision_score(y_test, predicted_rfc, average='weighted'),
In [21]:
          recall_score(y_test, predicted_rfc, average='weighted'))
Out[21]: (0.7567717408522097, 0.7570093457943925)
In [22]: f1 score(y test, predicted rfc, average='weighted')
Out[22]: 0.7566245963419206
In [23]:
         # n estimators = 50 (default)
         abc = AdaBoostClassifier().fit(X train, y train)
         predicted abc = abc.predict(X_test)
In [24]: | accuracy_score(y_test, predicted_abc)
Out[24]: 0.7289719626168224
In [25]: balanced accuracy score(y test, predicted abc)
Out[25]: 0.7284210526315789
         (precision_score(y_test, predicted_abc, average='weighted'),
In [26]:
          recall_score(y_test, predicted_abc, average='weighted'))
Out[26]: (0.7293842770753162, 0.7289719626168224)
In [27]:
        fl score(y test, predicted abc, average='weighted')
Out[27]: 0.7291144464706996
In [28]: rfc n range = np.array(range(5,100,5))
         rfc_tuned_parameters = [{'n_estimators': rfc_n_range}]
         rfc tuned parameters
Out[28]: [{'n_estimators': array([ 5, 10, 15, 20, 25, 30, 35, 40, 45, 50, 55,
         60, 65, 70, 75, 80, 85,
                  90, 951)}1
```

```
In [29]:
         import warnings
         from sklearn.model selection import GridSearchCV
         warnings.filterwarnings('ignore')
         gs_rfc = GridSearchCV(RandomForestClassifier(), rfc_tuned_parameters,
                               scoring='accuracy')
         gs rfc.fit(X train, y train)
Out[29]: GridSearchCV(cv=5, error_score='raise-deprecating',
                estimator=RandomForestClassifier(bootstrap=True, class weight
         =None, criterion='gini',
                     max depth=None, max features='auto', max leaf nodes=None
                     min impurity decrease=0.0, min impurity split=None,
                     min samples leaf=1, min samples split=2,
                     min weight fraction leaf=0.0, n estimators='warn', n job
         s=None,
                     oob score=False, random state=None, verbose=0,
                     warm start=False),
                fit params=None, iid='warn', n jobs=None,
                param grid=[{'n estimators': array([ 5, 10, 15, 20, 25, 30, 3
         5, 40, 45, 50, 55, 60, 65, 70, 75, 80, 85,
                90, 951)}1,
                pre dispatch='2*n jobs', refit=True, return train score='warn
                scoring='accuracy', verbose=0)
In [30]: | gs_rfc.best_params
Out[30]: {'n estimators': 85}
In [31]: plt.plot(rfc n range, gs rfc.cv results ['mean test score'])
Out[31]: [<matplotlib.lines.Line2D at 0x1a1e9302e8>]
```



```
In [32]: abc n range = np.array(range(5,100,5))
         abc tuned parameters = [{'n estimators': abc n range}]
         abc tuned parameters
Out[32]: [{'n_estimators': array([ 5, 10, 15, 20, 25, 30, 35, 40, 45, 50, 55,
         60, 65, 70, 75, 80, 85,
                   90, 951)}1
In [33]: gs abc = GridSearchCV(AdaBoostClassifier(), abc tuned parameters, cv=5
                                scoring='accuracy')
         gs_abc.fit(X_train, y_train)
Out[33]: GridSearchCV(cv=5, error score='raise-deprecating',
                estimator=AdaBoostClassifier(algorithm='SAMME.R', base estima
         tor=None,
                    learning_rate=1.0, n_estimators=50, random_state=None),
                fit_params=None, iid='warn', n_jobs=None,
                param_grid=[{'n_estimators': array([ 5, 10, 15, 20, 25, 30, 3
         5, 40, 45, 50, 55, 60, 65, 70, 75, 80, 85,
                90, 95])}],
                pre_dispatch='2*n_jobs', refit=True, return_train score='warn
                scoring='accuracy', verbose=0)
In [34]: | gs_abc.best_params_
Out[34]: {'n estimators': 25}
In [35]: plt.plot(abc n range, gs abc.cv results ['mean test score'])
Out[35]: [<matplotlib.lines.Line2D at 0x1a1e985d68>]
          0.82
          0.81
          0.80
          0.79
          0.78
          0.77
                     20
                             40
                                     60
                                              80
```

```
In [37]: accuracy score(y test, predicted rfc opt)
Out[37]: 0.7663551401869159
In [38]: balanced_accuracy_score(y_test, predicted_rfc_opt)
Out[38]: 0.7635087719298246
         (precision_score(y_test, predicted_rfc_opt, average='weighted'),
In [39]:
          recall score(y test, predicted rfc opt, average='weighted'))
Out[39]: (0.7663352555179958, 0.7663551401869159)
In [40]:
         f1_score(y_test, predicted_rfc_opt, average='weighted')
Out[40]: 0.765737522265126
In [41]: abc optimized = RandomForestClassifier(n estimators=gs abc.best params
         predicted abc opt = abc optimized.predict(X test)
In [42]: | accuracy_score(y_test, predicted_abc_opt)
Out[42]: 0.7476635514018691
        balanced_accuracy_score(y_test, predicted_abc_opt)
In [43]:
Out[43]: 0.7471929824561403
In [44]:
         (precision_score(y_test, predicted_abc_opt, average='weighted'),
          recall score(y test, predicted abc opt, average='weighted'))
Out[44]: (0.748059504175502, 0.7476635514018691)
        f1_score(y_test, predicted_abc_opt, average='weighted')
In [45]:
Out[45]: 0.7477962087830651
```